

# Семинар 2


Математика для ML. Вычислительная линейная алгебра.

# Сегодня мы...

- ...узнаем, как линейная алгебра стала **самым важным** для компьютерных приложений разделом прикладной математики двадцатого века.
- ...вспомним её основные понятия.
- ...познакомимся с основными **матричными разложениями**. Научимся выводить **РСА** из интуитивных соображений.
- ...осознаем **рекомендательную систему** на основе **коллаборативной фильтрации** наподобие тех, что раньше использовались в рекламе **Я**ндекса.

# План

- ▶ **Мотивировка.**
- ▶ **Повторение: Основные понятия линейной алгебры.**
- ▶ **Матричные разложения.**  
**Вывод PCA.**
- ▶ **Коллаборативная фильтрация.**



# Мотивировка

Линейная алгебра — язык данных, понятный вашему компьютеру

## За последние 30 лет мы **научили машины**

- Смотреть и видеть;
- Слушать, слышать и говорить в ответ;
- Сочинять стихи и песни,
- Прогнозировать котировки бирж;
- Находить раковые опухоли

и многое другое.

**Диапазон приложений машинного обучения** **поражает воображение человека.**

Тем более удивительным кажется тот факт, что на всё это способна **обычная вычислительная машина.**

**Ликбез:** компьютер это очень глупая коробка:) Это я вам как программист говорю.

Он понимает только нули и единицы, но делает это очень хорошо.

Настолько хорошо, что если из нулей и единиц составить числа, то он сможет за секунду обработать больше чисел, чем вы за всю свою жизнь.




**Какой отсюда следует вывод?**


Фото, видео, звуки вашего голоса, стихи Маяковского — всё это нужно выразить на языке чисел.

И возможным это делает раздел математики под названием “линейная алгебра”.


# Линейная алгебра сделала возможной арифметику слов и...



Male-Female




Verb tense



Country-Capital



# ...генерацию лиц с заданными свойствами, и многое другое



Линейная алгебра это язык, на котором **задачу**  
**понимает машина.**

Наша сегодняшняя задача — стать  
переводчиками с одного языка на другой.

# Линейная алгебра

Повторение основных понятий





# Линейное пространство

Основопологающим понятием линейной алгебры является понятие **линейного пространства**.

**Пример:** множество вещественных векторов из  $n$  компонент (например  $(0, 0, 0, \dots, 0)$ )

**Что с ними можно делать?** Складывать (в любом порядке, в любой последовательности), умножать на вещественные числа.




# Линейное пространство

По жизни вам придётся иметь дело преимущественно с **вещественными векторами, матрицами и тензорами**.

**Тем не менее, линейные пространства на этом не исчерпываются.**

В общем случае, линейное пространство состоит из абелевой группы векторов (с операцией сложения), поля скаляров и операции умножения вектора на скаляр, согласованной со сложением векторов при помощи аксиом дистрибутивности.

Эти условия легко проверить.



# Примеры полезных линейных пространств

- Пространство **матриц** одинаковой размерности.
- Пространство **тензоров** (“многомерных” матриц) одинаковой размерности.
- Пространство **многочленов** (обычных или тригонометрических).
- Пространство **решений однородной системы линейных уравнений**, алгебраических или дифференциальных.
- Пространство **двоичных векторов** с операцией сложения по модулю 2 и операцией умножения на 0 и 1.

На этом занятии мы  
сосредоточимся на  
вещественных **векторах**,  
**матрицах** и связи между ними.

Поскольку именно с ними в  
большинстве своем работает  
Data Scientist

Feature-1	Feature-2	Feature-3	Feature-4	...	...	Feature-n	
$x_1^1$	$x_2^1$	$x_3^1$	$x_4^1$	...	...	$x_n^1$	Sample-1
$x_1^2$	$x_2^2$	$x_3^2$	$x_4^2$	...	...	$x_n^2$	Sample-2
$x_1^3$	$x_2^3$	$x_3^3$	$x_4^3$	...	...	$x_n^3$	Sample-3
...	...	...	...	...	...	...	
$x_1^m$	$x_2^m$	$x_3^m$	$x_4^m$	...	...	$x_n^m$	Sample-m

# Важные понятия линейной алгебры

**Определение:** (Матрица) Представление чисел в виде таблицы.

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 2 & -1 \\ 3 & 4 & 0 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix}$$

**Определение:** (Транспонированная матрица) Зеркально отображенная относительно диагонали матрица.

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}^T = \begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 2 & -1 \\ 3 & 4 & 0 \end{pmatrix}^T = \begin{pmatrix} 1 & 3 \\ 2 & 4 \\ -1 & 0 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix}^T = \begin{pmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \end{pmatrix}$$



# Важные понятия линейной алгебры

**Определение:** (Единичная матрица) Квадратная матрица, у которой на диагонали стоят единицы, а на всех остальных местах нули. (обычно обозначают  $I$  или  $E$ )

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

**Определение:** (Диагональная матрица) Матрица, у которой на диагонали стоят любые числа, а на всех остальных местах нули.

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\begin{pmatrix} 5 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 10 \end{pmatrix}$$

$$\begin{pmatrix} -7 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 70 \end{pmatrix}$$

# Важные понятия линейной алгебры

***Умножение матрицы на вектор:***

$$\begin{pmatrix} 1 & 5 \\ 3 & 8 \end{pmatrix} \cdot \begin{pmatrix} -1 \\ 1 \end{pmatrix} = \begin{pmatrix} 4 \\ 5 \end{pmatrix} \quad \left| \quad (2 \ 3) \cdot \begin{pmatrix} 1 \\ 1 \end{pmatrix} = 5 \quad \left| \quad \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} =$$

***Умножение матрицы на матрицу:***

$$\begin{pmatrix} -1 & 3 \\ 4 & 0 \end{pmatrix} \cdot \begin{pmatrix} -1 & 4 \\ 3 & 0 \end{pmatrix} = \begin{pmatrix} 10 & -4 \\ -4 & 16 \end{pmatrix} \quad \left| \quad \begin{pmatrix} -1 & 3 & 1 \\ 4 & 0 & -1 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{pmatrix} =$$

# Важные понятия линейной алгебры

**Определение:** (Обратная матрица) Такая матрица, при умножение на которую, исходная матрица станет единичной. (обозначают верхним индексом -1)

$$A \cdot A^{-1} = I$$

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$$

$$A^{-1} = \begin{pmatrix} -2 & 1 \\ 3/2 & -1/2 \end{pmatrix}$$

$$A^{-1} \cdot A = A \cdot A^{-1} =$$


В общем случае, находить обратную матрицу очень сложно и это на практике часто делают приближенно.

# Базис линейного пространства

Во всяком линейном пространстве есть несколько главных векторов, — так называемый **базис**. Остальные вектора **выражаются** через базисные.

Количество базисных векторов определяет **размерность пространства**.

**Пример:** В случае  $\mathbb{R}^n$  базисных векторов **ровно  $n$** . Они задают **координатные оси**.



# Базис линейного пространства

**Базис** — такое минимальное по включению множество векторов, что:

- Ни один из них не выражается линейной комбинацией остальных;
- Каждый элемент пространства можно единственным образом представить линейной комбинацией конечного набора векторов из этого множества.

Доказать, что **всякое линейное пространство имеет базис**, можно при помощи леммы Цорна.

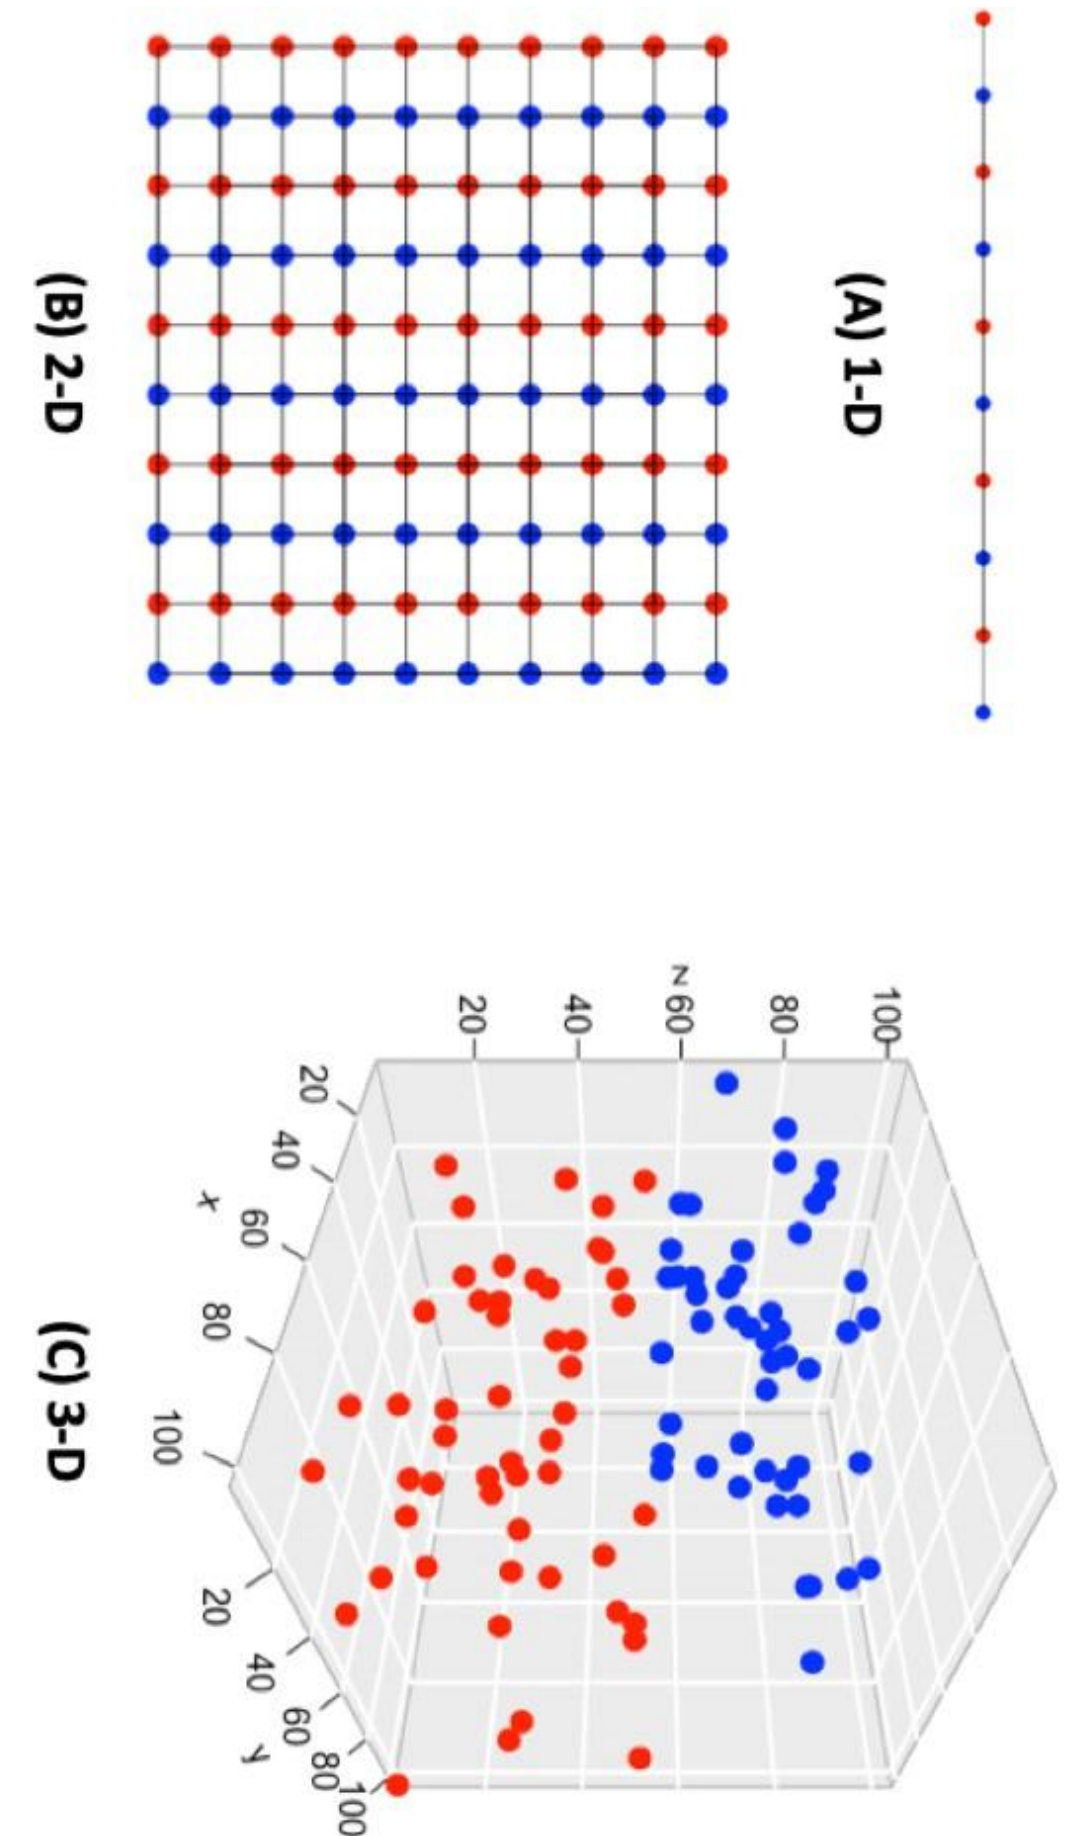


# Размерность линейного пространства

**Размерность** — одна из главных характеристик линейного пространства.

**Размерность в точности совпадает с числом базисных векторов.**

В машинном обучении есть даже одноимённое [проклятие](#):)





# Важные понятия линейной алгебры

**Определение:** (детерминант/определитель) Численная характеристика матрицы, которая которая в некотором смысле описывает сжатие или растяжение пространства при преобразовании этой матрицей.

$$\det \begin{pmatrix} -1 & -1 \\ 1 & 3 \end{pmatrix} = (-1) \cdot 3 - (-1) \cdot 1 = -2$$

Если связать получившееся значение с геометрическим смыслом, то если рассмотреть то, что мы матрицей преобразуем единичный квадрат, то:

- Знак минус будет говорить, что наш квадрат будет иметь противоположную ориентацию
- Значение 2 будет говорить о том, что после преобразования наш квадрат будет иметь площадь, в два раза превосходящую площадь оригинального квадрата.

*Мы опустим алгоритм подсчета определителя для матриц большего порядка.*

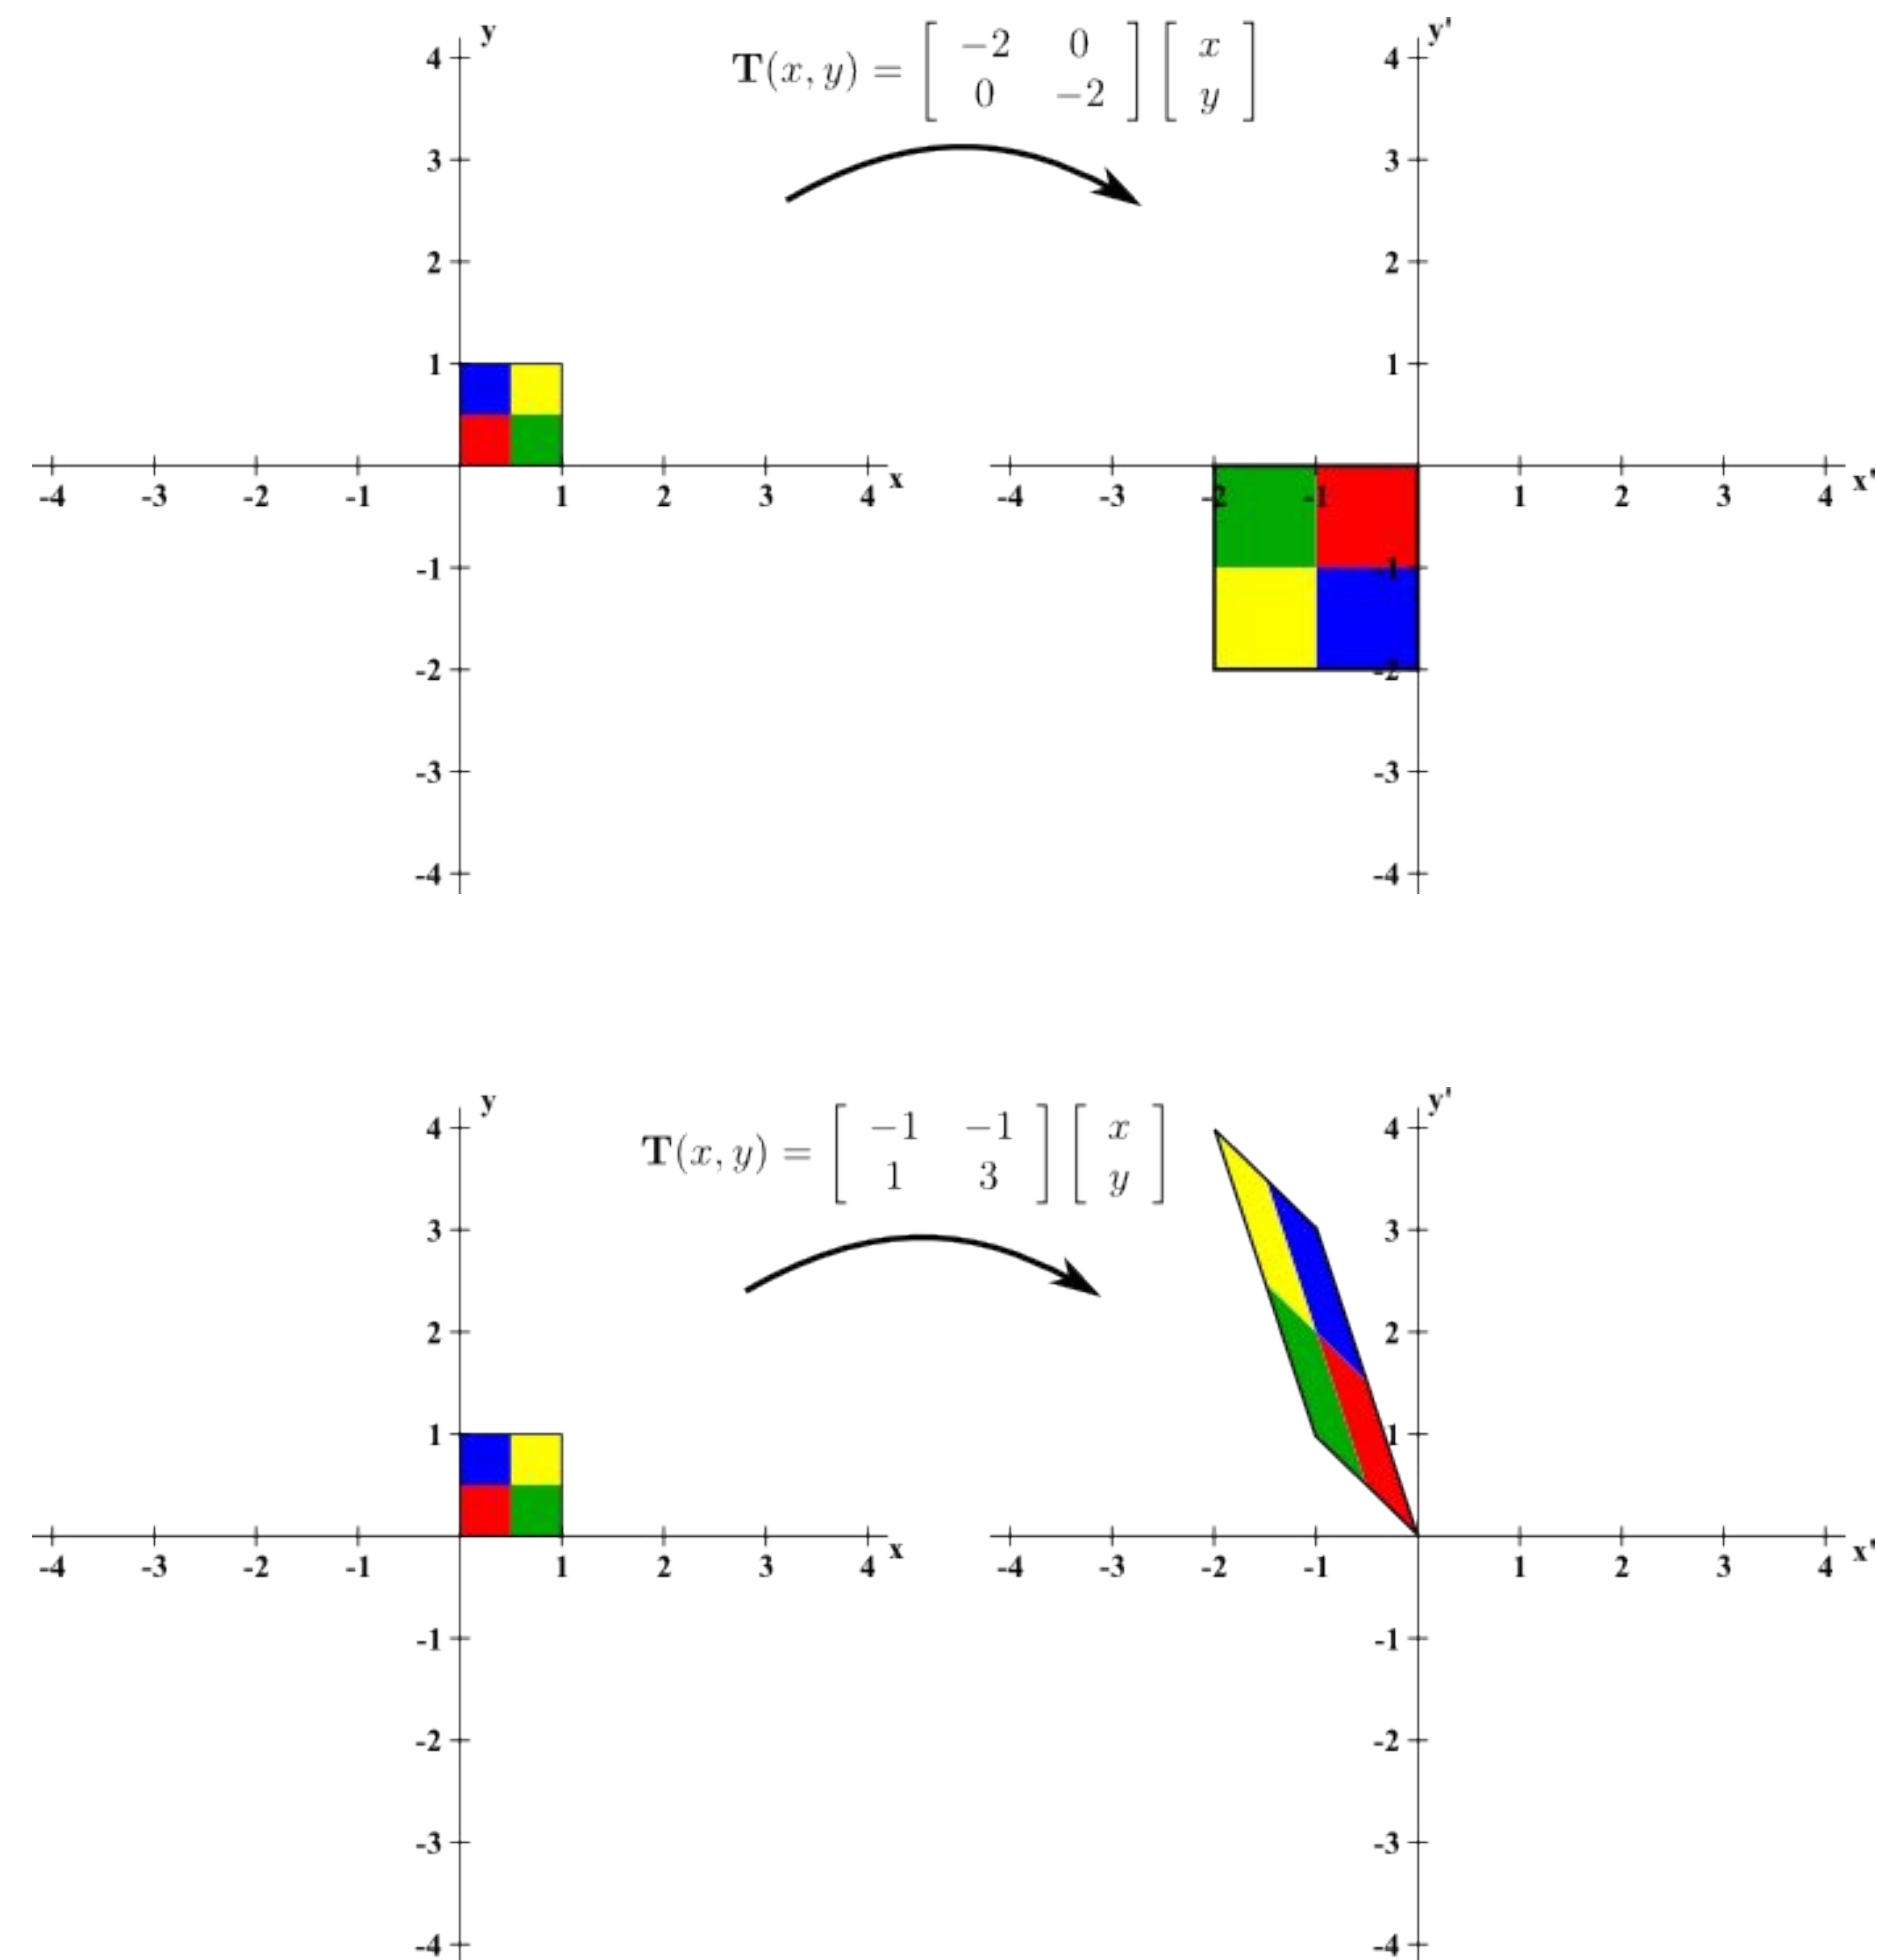
# Что касается матриц:

Каждая матрица кодирует **линейное преобразование линейных пространств** в некоторой системе координат: одно пространство отображается на подпространство другого.

Все эти преобразования можно разложить на комбинацию **проекций, вращений, отражений** и **масштабирования** вдоль координатных осей. Других преобразований нет.


Одному преобразованию можно сопоставить бесконечное количество матриц! Столько же, сколько есть систем координат. Сама по себе матрица это просто таблица чисел!

$$\begin{pmatrix} -1 & -1 \\ 1 & 3 \end{pmatrix} \cdot \begin{pmatrix} x \\ y \end{pmatrix} =$$

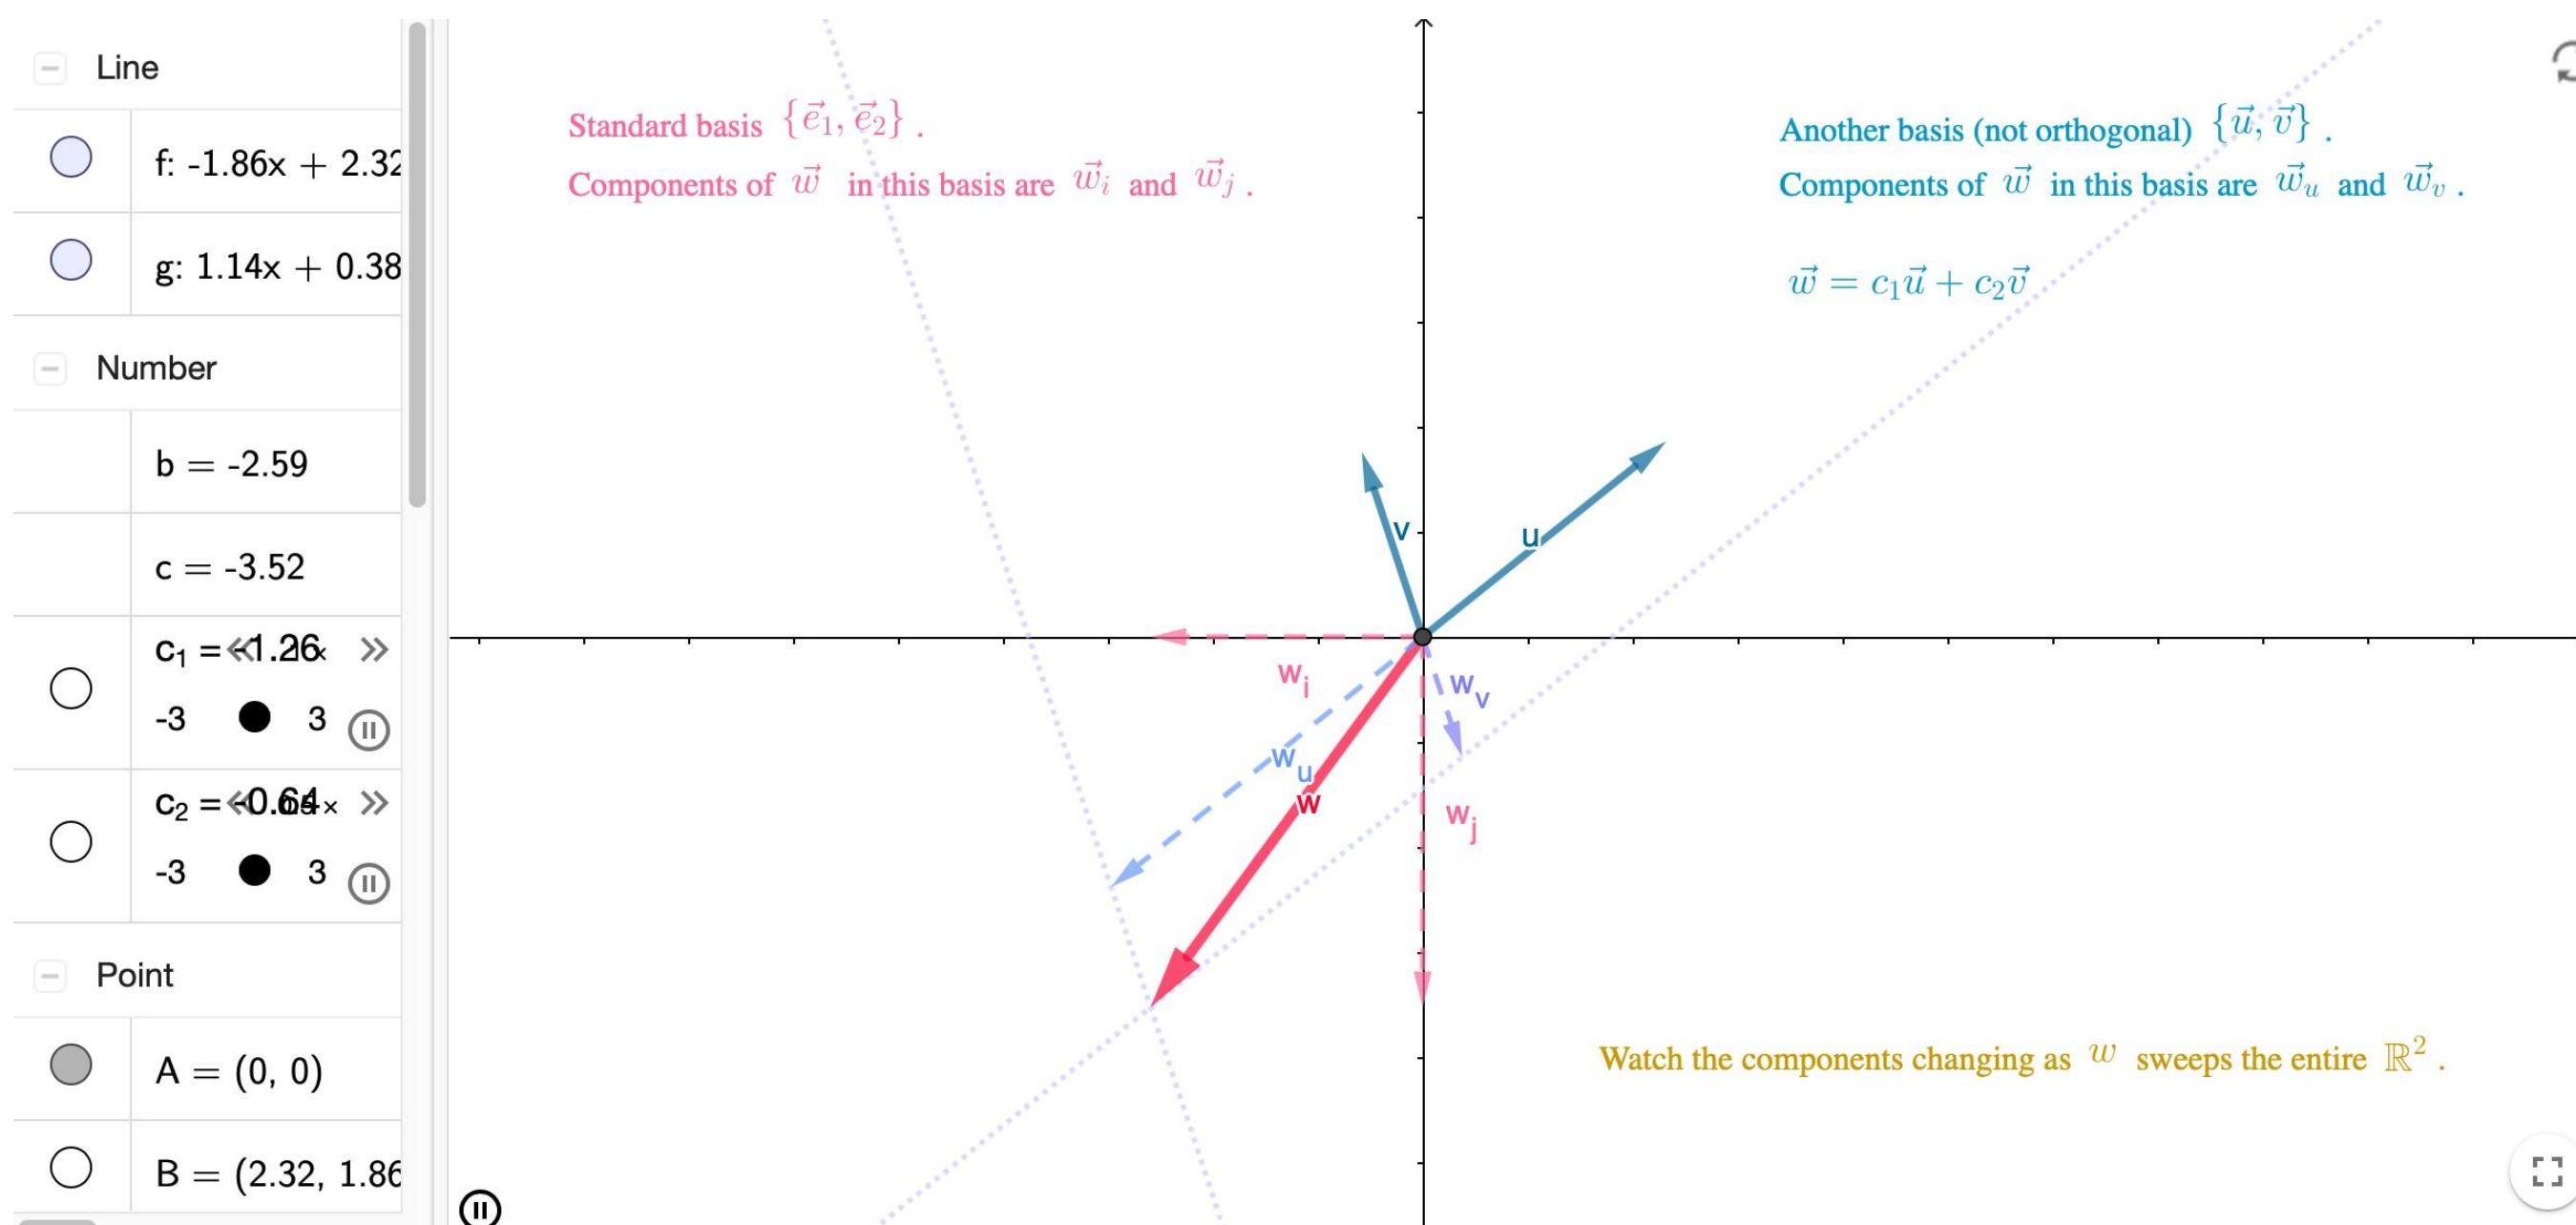




“Потрогать” это определение можно на [GeoGebra](#)



Наблюдать за тем, как замена базиса влияет на координаты векторов, тоже можно на [GeoGebra](#)



# Собственные направления

У линейного преобразования  $A : V \rightarrow V$  есть некоторое количество **собственных** направлений.

Вдоль них оно **не вращает**, **не отражает**, а **масштабирует**.

Это пример т.н. **инвариантных подпространств**: они не изменяются под действием  $A$ .

Формулами это задаётся так:

$$Av = \lambda v$$

- ▶  $\lambda$  — собственное значение
- ▶  $v$  — собственный вектор

Например:

$$A = \begin{pmatrix} 1 & 2 \\ -1 & 4 \end{pmatrix}$$

$$v = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$$

Понятие собственных направлений очень полезно, поскольку позволяет находить “хорошие” направления нашего преобразования и, кроме того, если собственных векторов окажется столько, сколько базисных, то мы сможем “перейти” в базис собственных векторов, в котором наша матрица  $A$  будет иметь диагональный вид, что упрощает многие выкладки.

*У собственных направлений, например, может быть следующий физический смысл: В теории колебаний собственные числа это частоты колебаний системы при свободном движении, а собственные вектора это их «траектории».*

# Матричные разложения

**SVD** и его связь с **PCA** (метод главных векторов)

**Матрицы признаков** прямоугольные вещественные матрицы размера  $m \times n$ , где:

$m$  – размер выборки

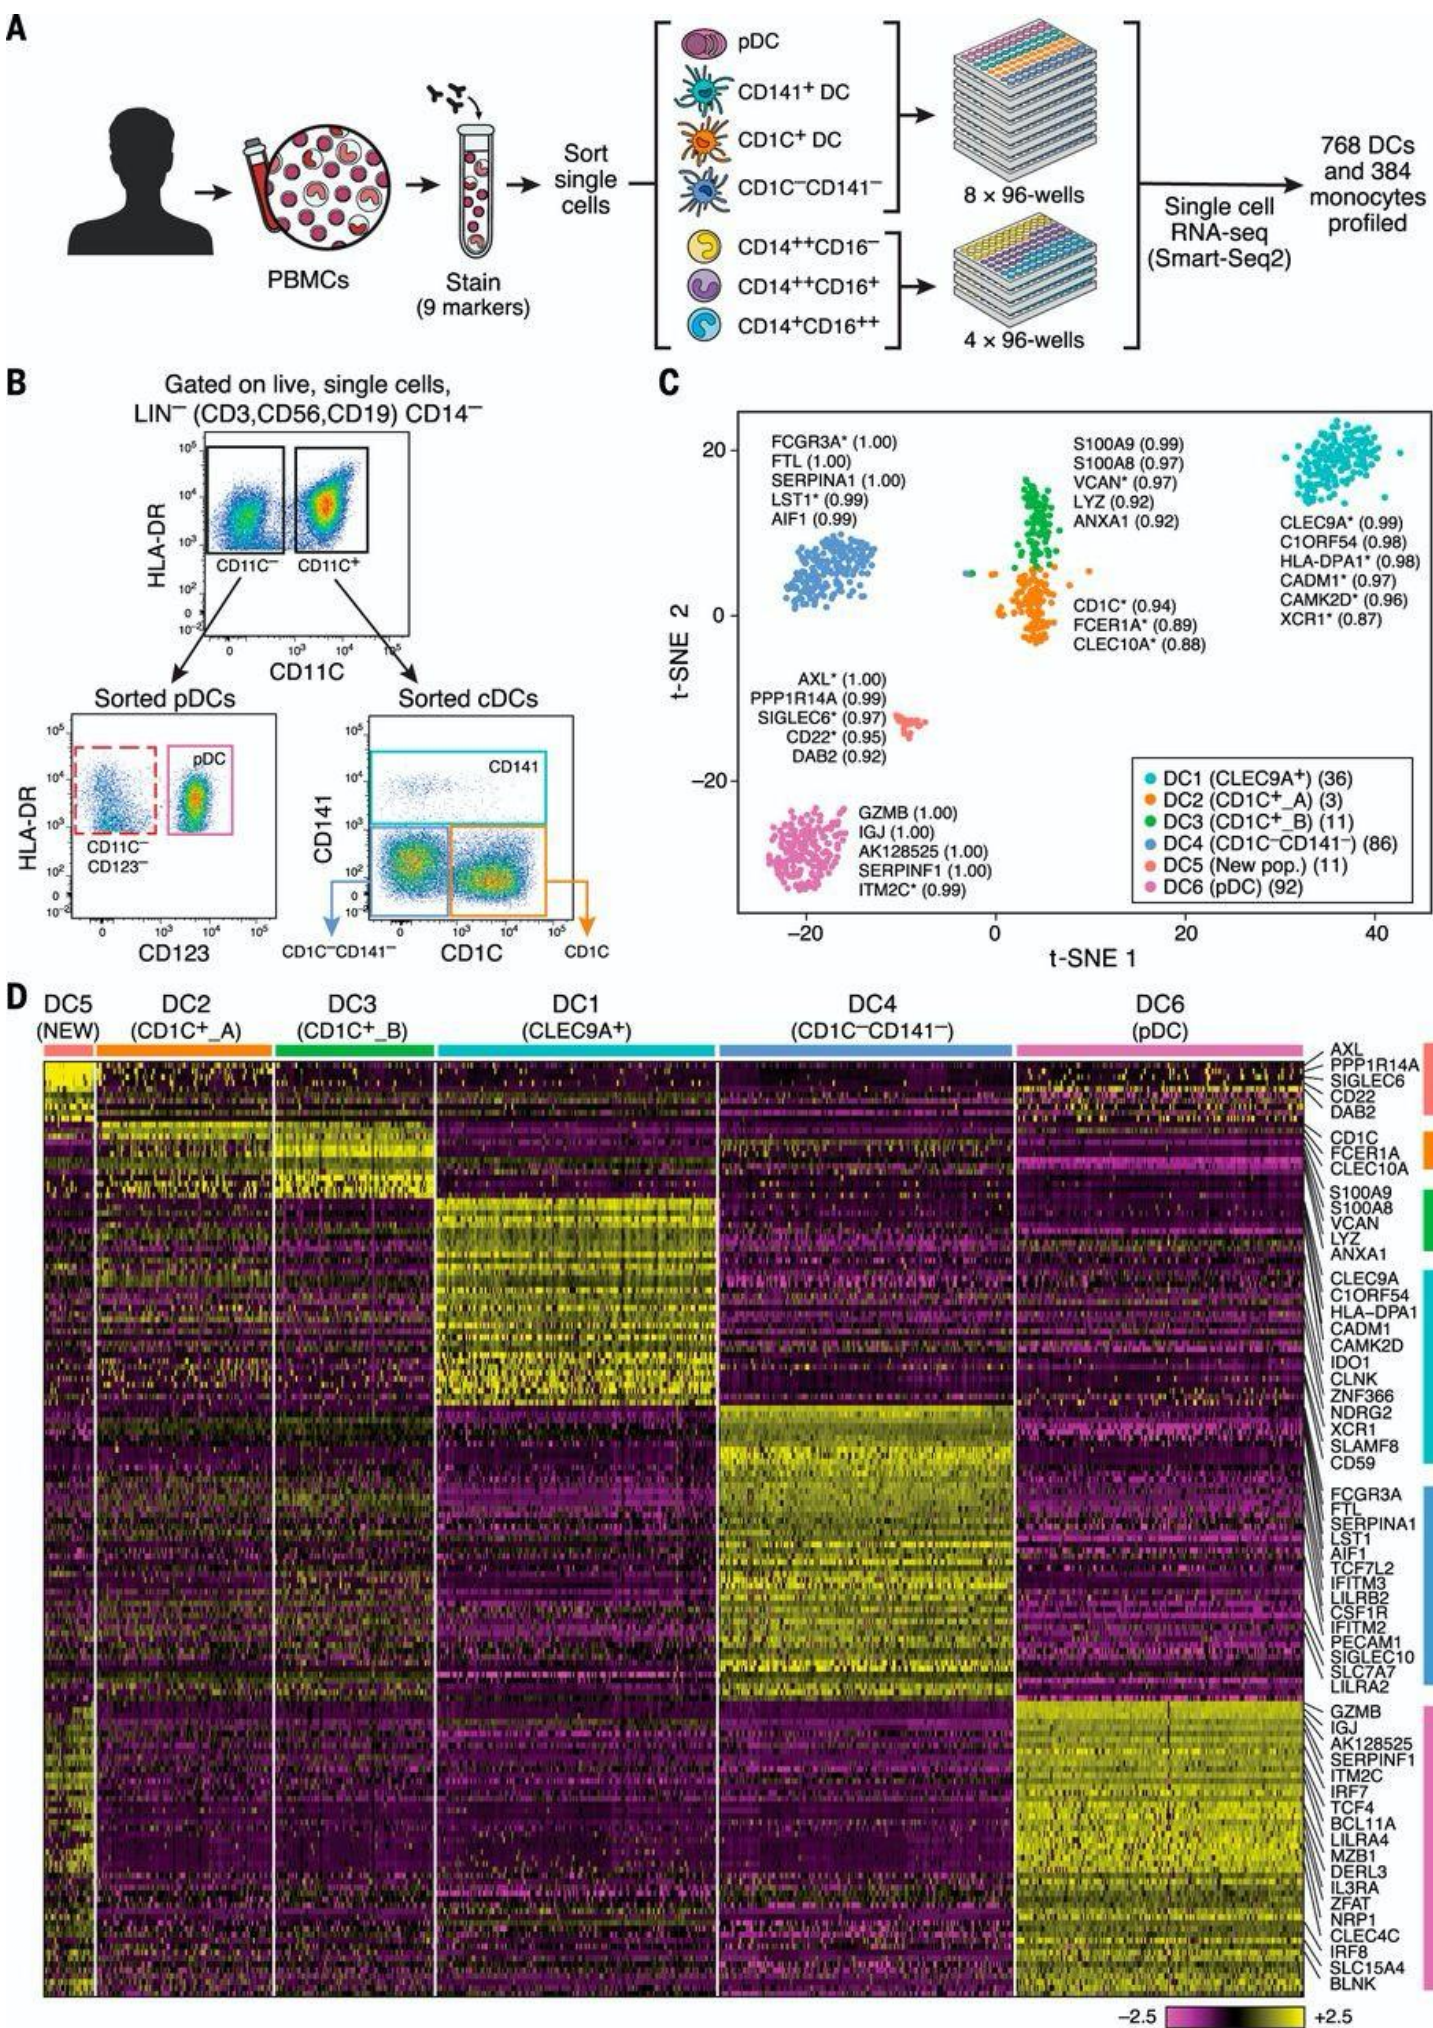
$n$  – количество признаков (и размер признакового пространства)

Feature-1	Feature-2	Feature-3	Feature-4	...	...	Feature-n	
$x_1^1$	$x_2^1$	$x_3^1$	$x_4^1$	...	...	$x_n^1$	Sample-1
$x_1^2$	$x_2^2$	$x_3^2$	$x_4^2$	...	...	$x_n^2$	Sample-2
$x_1^3$	$x_2^3$	$x_3^3$	$x_4^3$	...	...	$x_n^3$	Sample-3
...	...	...	...	...	...	...	
$x_1^m$	$x_2^m$	$x_3^m$	$x_4^m$	...	...	$x_n^m$	Sample-m



Линейная алгебра — инструмент, который позволяет вам работать с данными **огромной размерности**.

**Пример:** типичная клетка опухоли в данных секвенирования это **14000 чисел**, а образец обычно содержит от ста до **миллиона** клеток.






Тем не менее, наш мозг **не в состоянии** воспринимать данные высокой размерности.

Всё, что выше **размерности 7** (длина, ширина, высота, три цвета, время) — **за гранью** нашего восприятия.


Даже простейшие геометрические объекты в духе **куба** становится практически невозможно изобразить **без потери информации**.



Укладка многомерных кубов  
(гиперкубов) на плоскости

К счастью, реальные данные обычно лежат на т.н. **маломерных многообразиях**.

Они **не** распределены по многомерному пространству **равномерно**, а лежат на поверхностях **существенно меньшей размерности**.




Формально это трёхмерные данные, но по факту они лежат на **двумерной** полосе



Определением **тонкой геометрической структуры** данных занимается раздел ML под названием **manifold learning**.

Но часто понизить размерность, скажем, с **14000** до **30-100** без существенной потери информации можно и при помощи более простых методов.

Например, при помощи **РСА — метода главных компонент**, который ищет оптимальное приближение размерности для вашей матрицы данных.



# Метод главных компонент (РСА)



Алгоритм работы РСА можно описать следующими шагами:

1. Найти такое направление в пространстве, вдоль которого **дисперсия данных максимальна**.
2. Среди оставшихся направлений, **ортогональных предыдущим**, найти направление вдоль которого **дисперсия максимальна**.
3. **Повторять шаг 2** до тех пор, пока это **ВОЗМОЖНО**.

Получившиеся направления и называют главными компонентами.

Мы могли бы находить такие направления полным перебором, но сколько бы это заняло времени хотя бы в 10-мерном пространстве?)

Поэтому мы, как настоящие математики, воспользуемся доступным мат. аппаратом, чтобы решить эту задачу!



# Важные понятия линейной алгебры

**Определение:** (Ортогональная матрица) Матрица, для которой обратная матрица совпадает с транспонированной.

$$A \cdot A^T = A \cdot A^{-1} = I$$

Например: 
$$\begin{pmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix}$$

**Определение:** (Сингулярные направления и значения)

$$\begin{aligned} Mv &= \sigma u \\ M^T u &= \sigma v \end{aligned}$$


здесь  $v$  – правый сингулярный вектор,  $u$  – левый сингулярный вектор,  $\sigma$  – сингулярное значение.

Сингулярное значение это корень из собственного значения матрицы  $M^T M$  (что мы можем легко проверить прямо здесь)

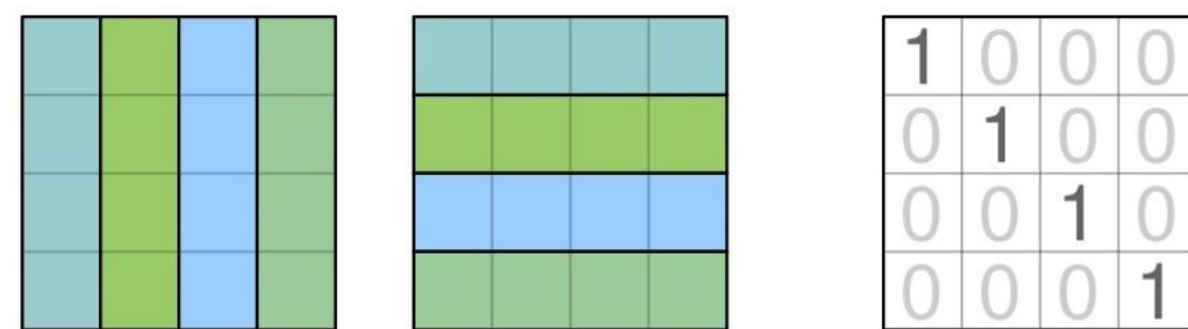
Сингулярные вектора и значения это в некотором смысле аналоги собственных векторов и чисел для неквадратных матриц. Причем если матрица квадратная, то квадрат сингулярного значения равен модулю соответствующего собственного значения (если такое существует).

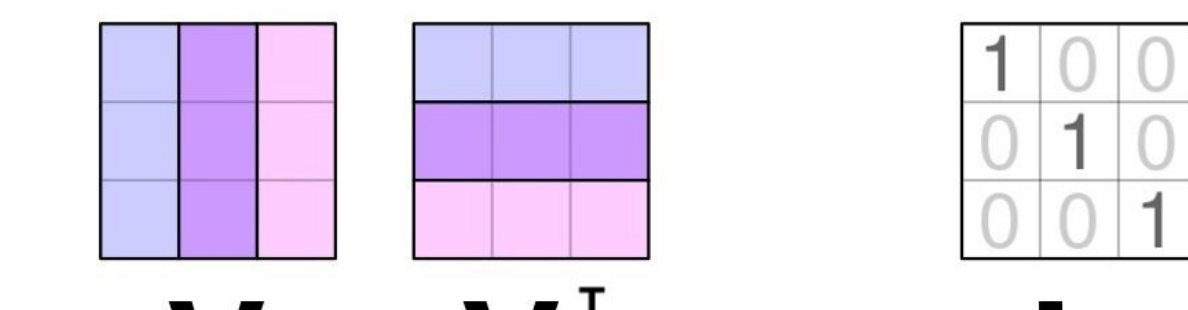


# Сингулярное (SVD) разложение матрицы




$$\mathbf{M}_{m \times n} = \mathbf{U}_{m \times m} \mathbf{\Sigma}_{m \times n} \mathbf{V}^T_{n \times n}$$



$$\mathbf{U}_{m \times m} \mathbf{U}^T_{m \times m} = \mathbf{I}_m$$



$$\mathbf{V}_{n \times n} \mathbf{V}^T_{n \times n} = \mathbf{I}_n$$

- $M \in \mathbb{R}^{m \times n}$  — Исходная матрица;
- $U \in \mathbb{R}^{m \times m}$  — Матрица **левых сингулярных** векторов;
- $\Sigma \in \mathbb{R}^{m \times n}$  — Матрица, на главной диагонали которой находятся т.н. **сингулярные числа**, (в порядке невозрастания);
- $V \in \mathbb{R}^{n \times n}$  — Матрица **правых сингулярных** векторов.



$$M = U \cdot \Sigma \cdot V^T$$

Выглядит жутковато...






# Усечённое SVD-разложение ранга $r$

матрицы  $M^{m \times n} \in \mathbb{R}$

— обычное SVD-разложение, где оставили только **самых больших** сингулярных значений вместе с соответствующими сингулярными векторами.



Можно доказать, что **усечённое SVD-разложение ранга  $r$**  это **оптимальная по Фробениусовой норме аппроксимация ранга  $r$** .

Поздравляю, благодаря этому факту мы можем сформулировать алгоритм **метод главных компонент**. :)

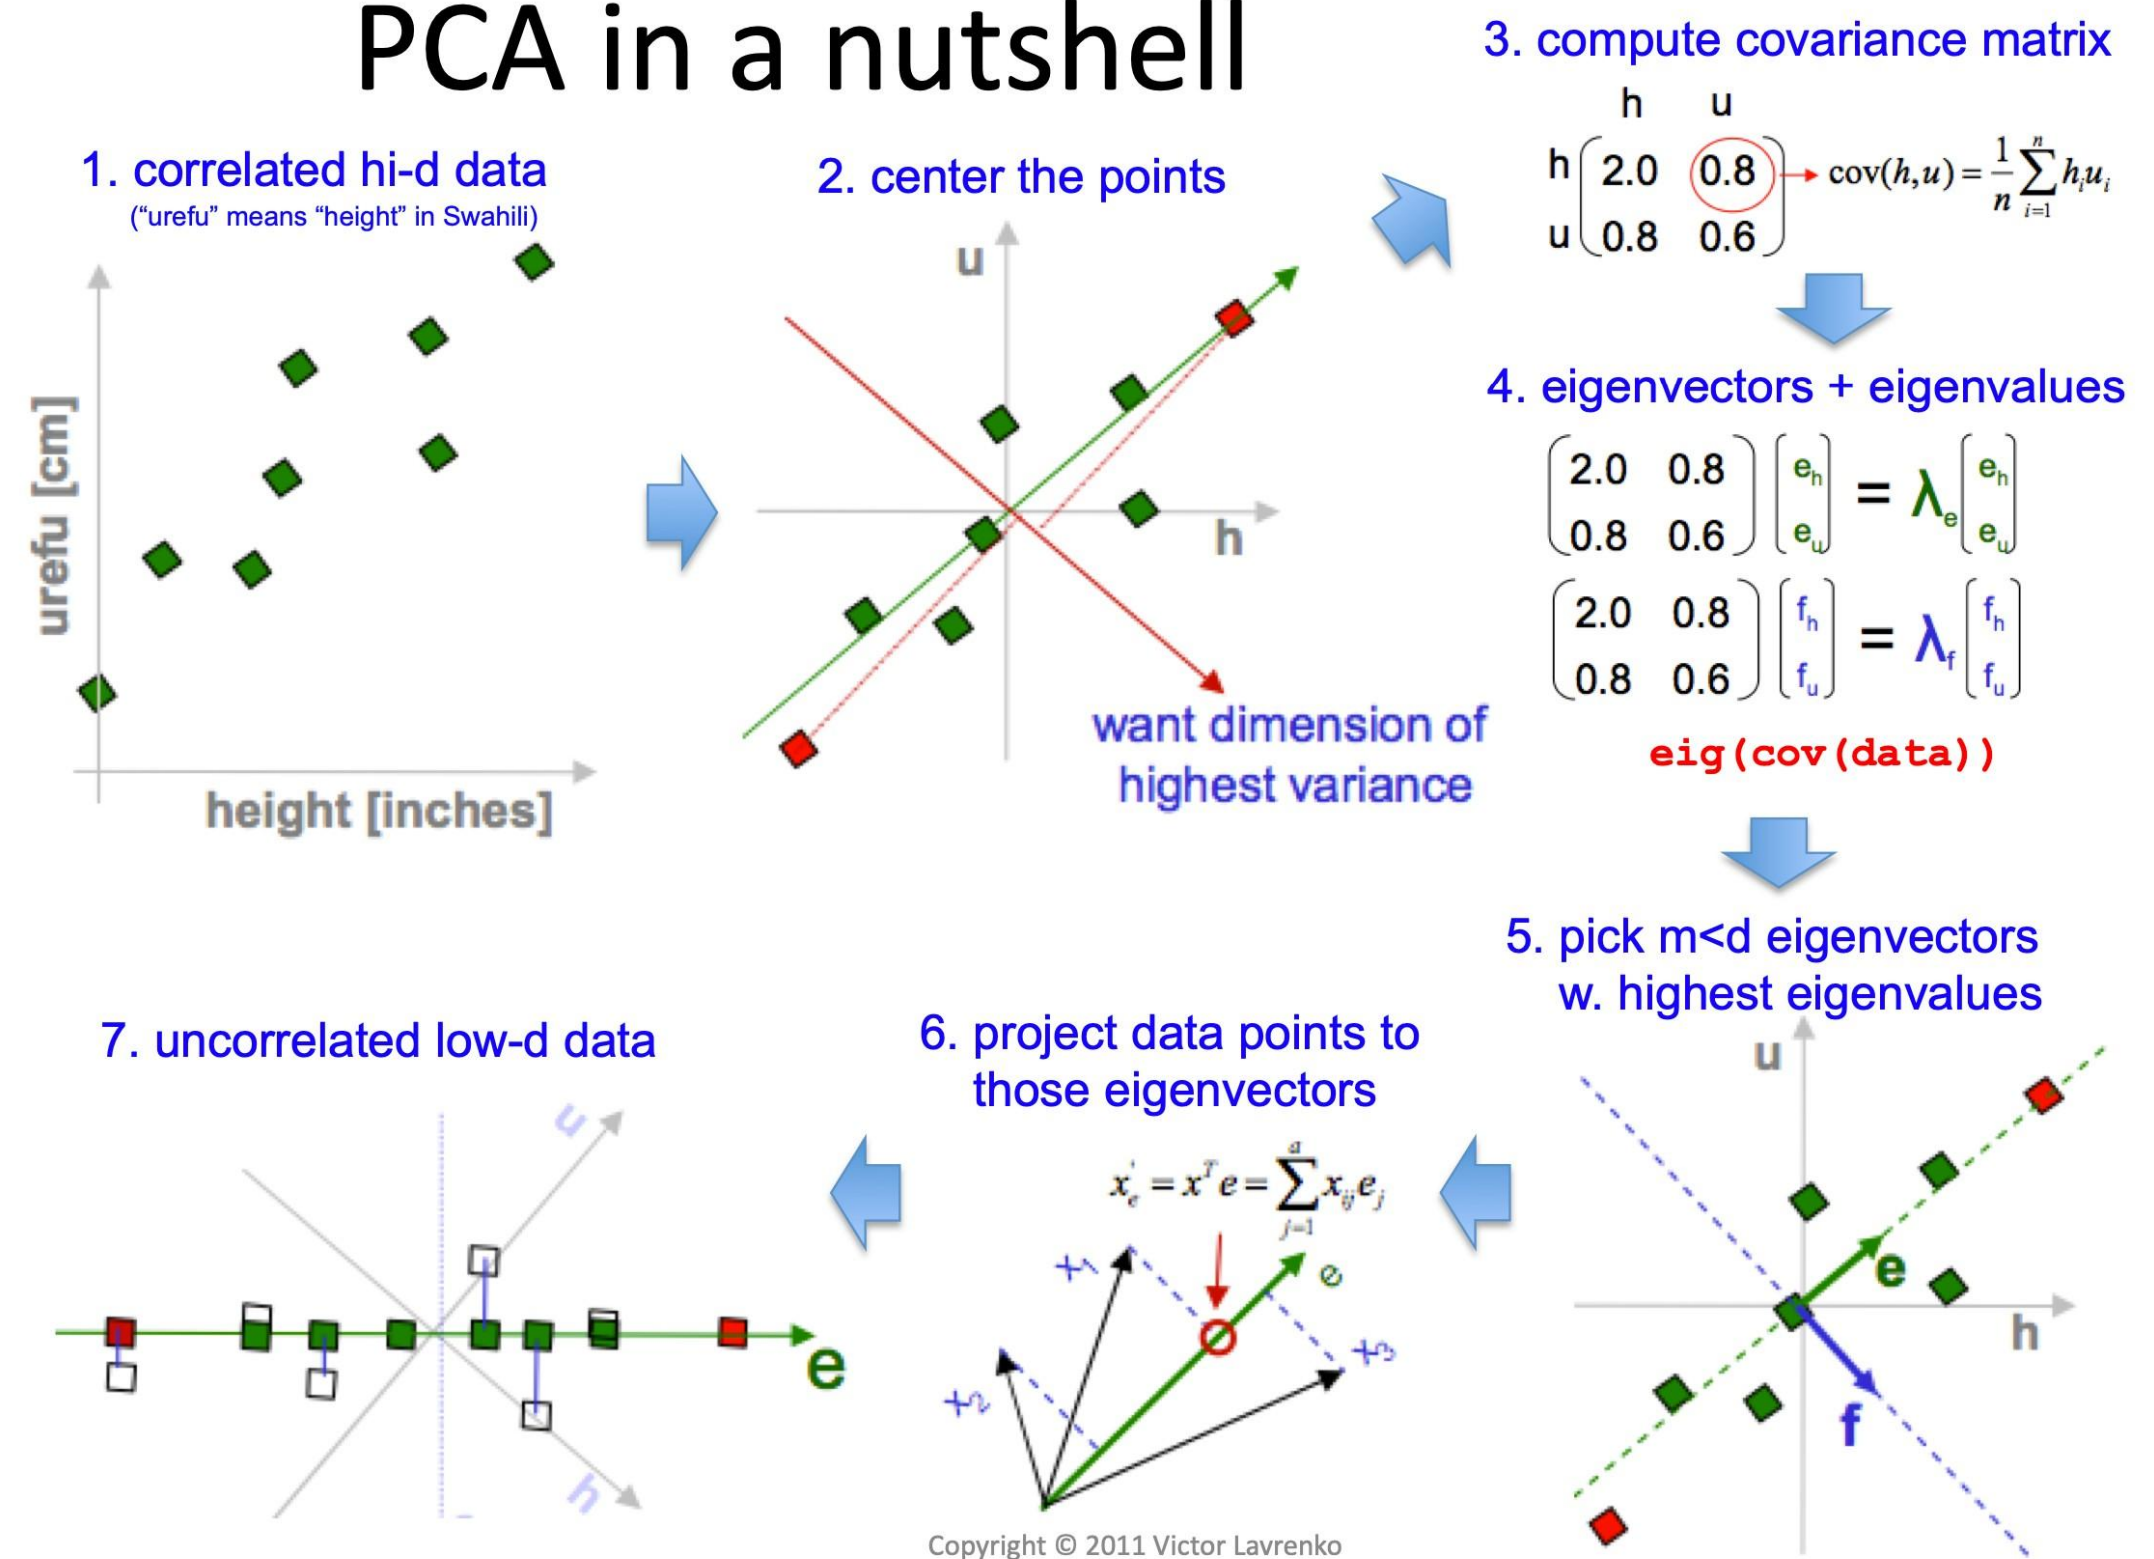
Норма Фробениуса, или **евклидова норма** (для евклидова пространства) представляет собой частный случай  $p$ -нормы для  $p = 2$ :  $\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}$ .

# Связь SVD и PCA

**PCA** преобразование можно было делать при помощи **нахождения собственных векторов** (как на алгоритме справа), но к сожалению почти всегда наши **датасете имеют разное число строк и столбцов** и поэтому мы вынуждены использовать **SVD**.

Но есть и хорошая новость! Для того, чтобы получить **PCA** преобразование, достаточно всего лишь **посчитать  $U\Sigma$** , то есть **произведение первых двух матриц в разложении SVD**.

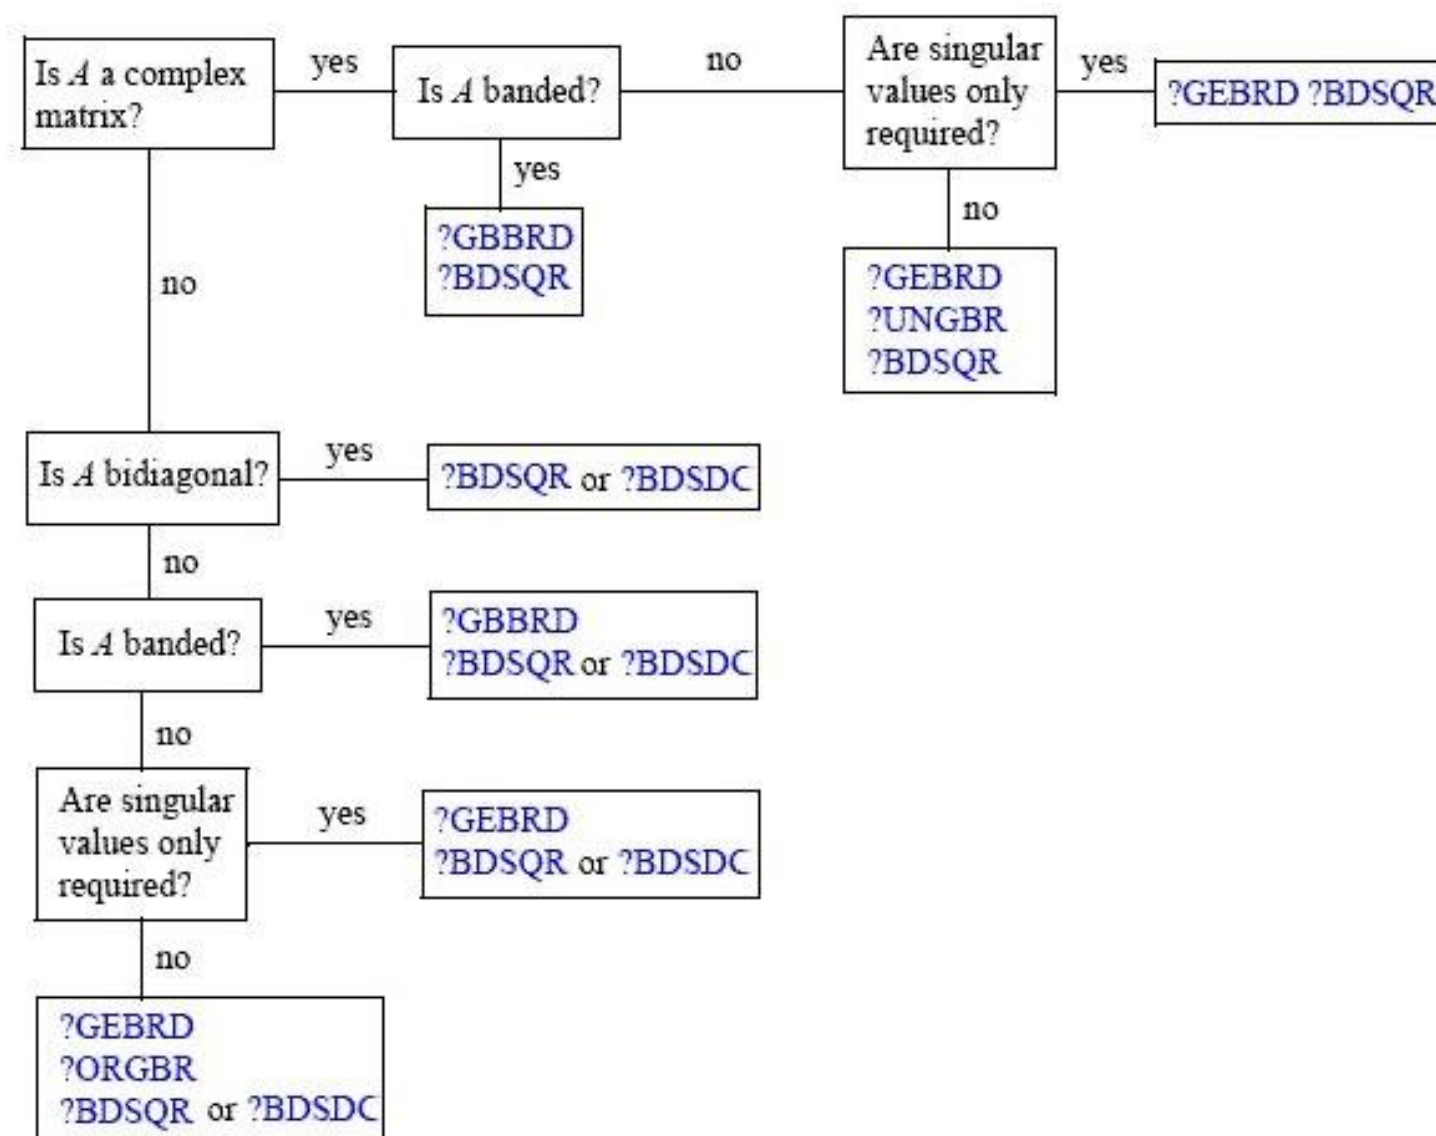
## PCA in a nutshell





Конкурентное преимущество SVD - разложения в том, что для его вычисления есть **эффективные алгоритмы**.

В том числе для **огромных разреженных матриц**, которые часто встречаются на практике (в рекомендательных системах, биоинформатике etc).



Упрощённая схема вычисления **SVD-разложения**. На каждый случай — свой алгоритм!

И это, ещё, без учёта **разреженности** матрицы.

Но не **PCA** единым хорош **SVD**!

# Приложения SVD

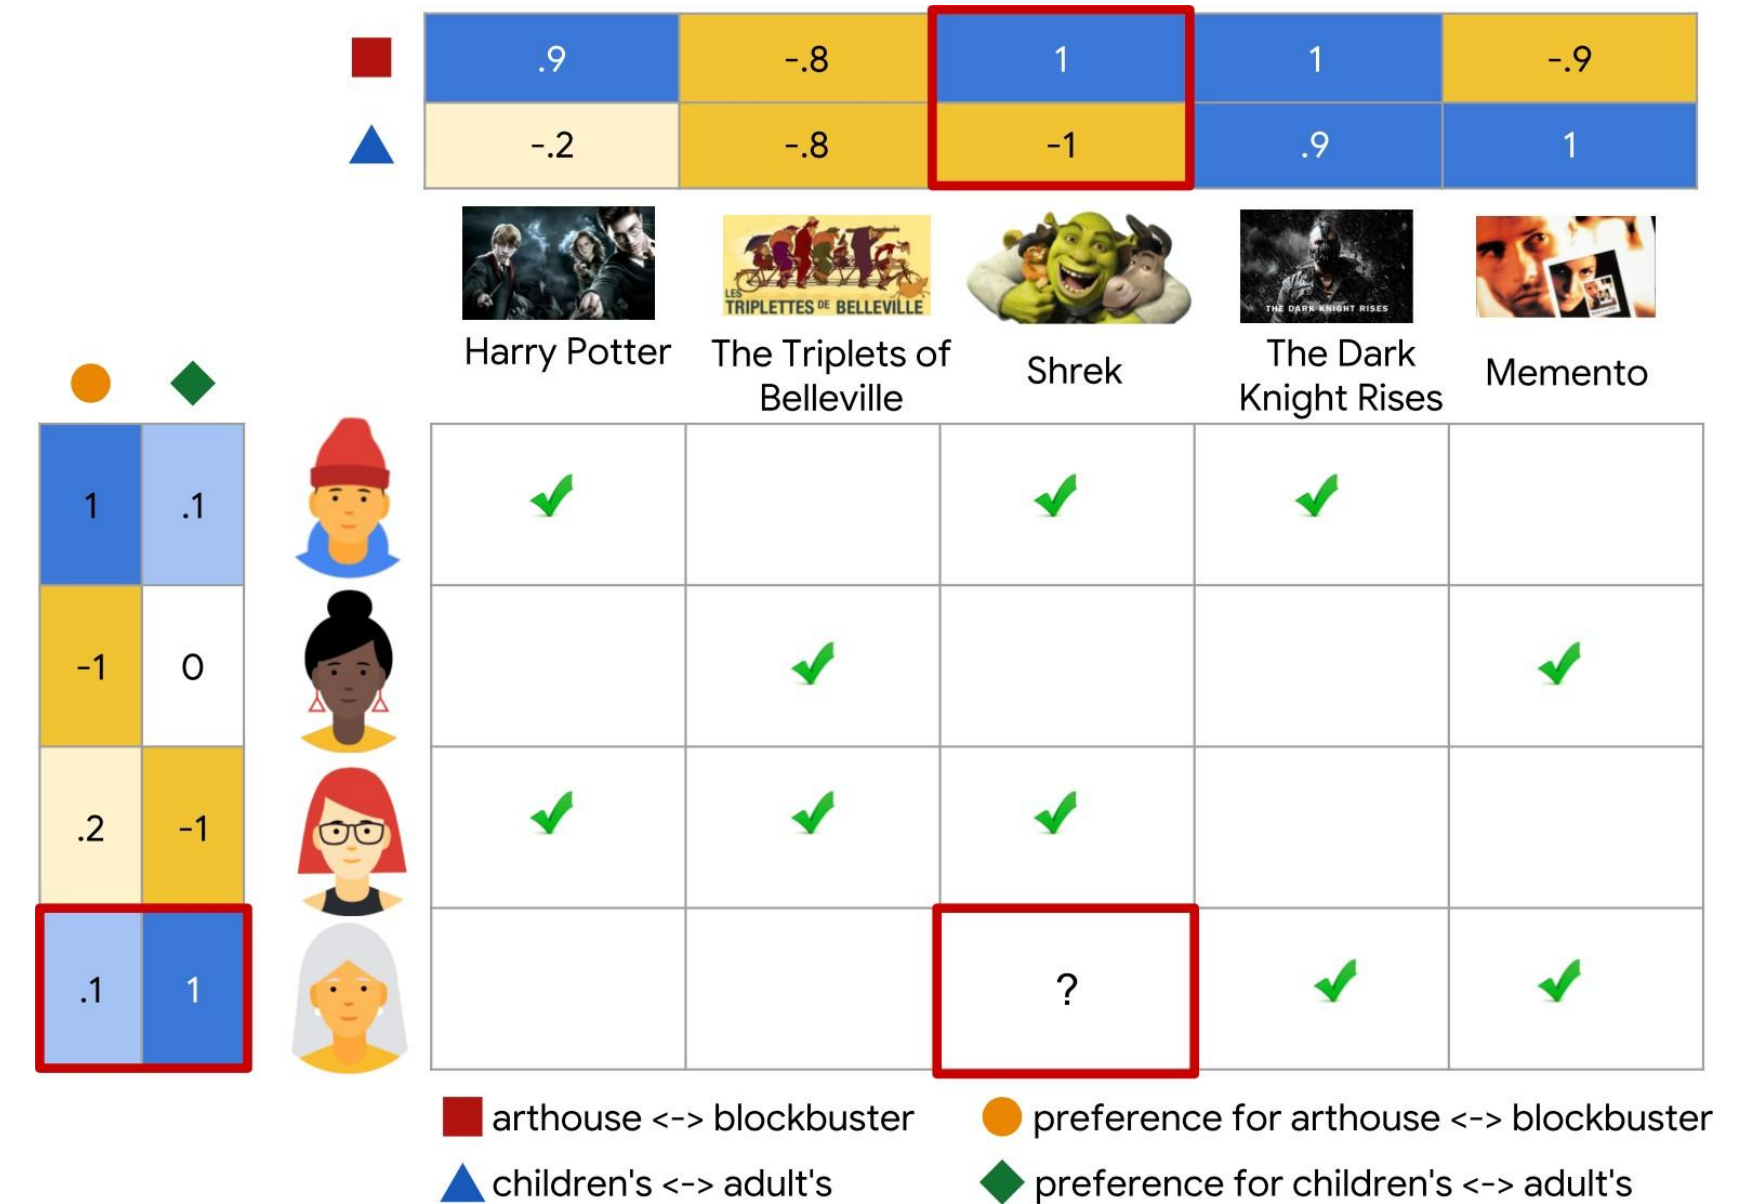
Коллаборативная фильтрация и многое другое

В задачах рекомендации важную роль играет **матрица взаимодействий пользователя с контентом**.

Представьте Netflix:

- **Миллионы** пользователей;
- **Тысячи** фильмов и сериалов;
- Каждый пользователь, в среднем, смотрит < 100 из них.

**Гигантская разреженная матрица.** На пересечении (пользователь, столбец) — **оценка** или любая другая полезная информация ("посмотрел ли до конца" и другие прокси-метрики)

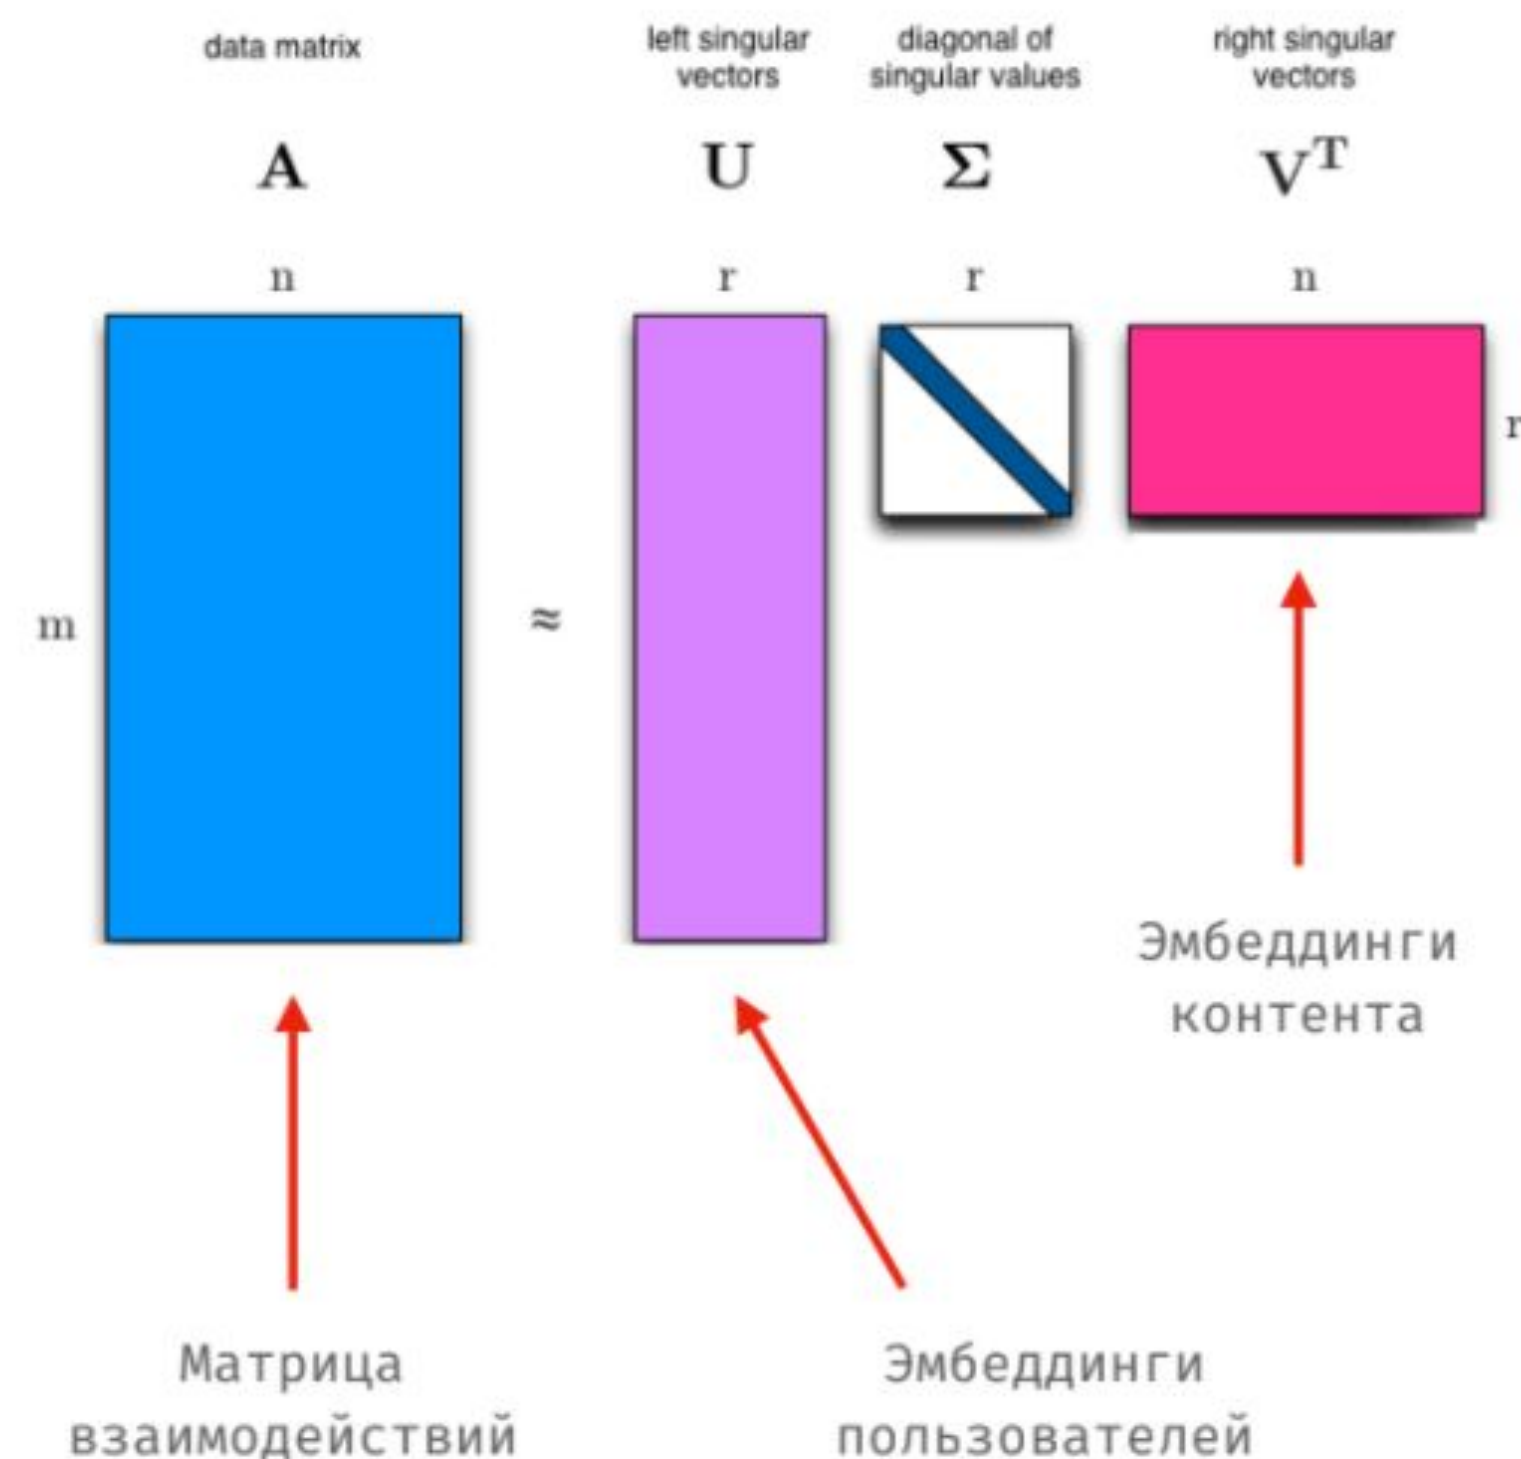


<https://developers.google.com/machine-learning/recommendation/collaborative/basics>

**Усеченное SVD-разложение ранга  $r$  матрицы взаимодействий** позволяет получить **эмбединги** размерности  $r$  как для **пользователей**, так и для **контента**!

**Более того:** чем больше скалярное произведение эмбедингов пользователя и контента, тем выше шанс, что пользователю понравится контент!

Это позволяет построить простейшую **рекомендательную систему**!



**Рекомендательные системы на основе коллаборативной фильтрации** — основа рекомендательных систем в Яндексе — в рекламе, Дзене и т.д.

Разумеется, там используются более продвинутые матричные факторизации. Но идея та же.




Статья про коллаборативную фильтрацию в Яндекс.  
Дзене:

<https://habr.com/ru/company/yandex/blog/490140/>




Кроме того, SVD - разложение  
можно использовать как  
механизм сжатия  
изображений и видео...

Detail from Durer's Melancholia, dated 1514., 359x371 image



EOF reconstruction with 50 modes



[http://www.columbia.edu/itc/applied/e3101/SVD\\_applications.pdf](http://www.columbia.edu/itc/applied/e3101/SVD_applications.pdf)